

LAPORAN PROJECT PENAMBANGAN DATA  
SEMESTER GENAP 2024/2025

IDENTITAS PROYEK	
Judul	Analisis Pola Kriminalitas Spatio-Temporal menggunakan Association Rule Mining dengan Apriori dan FP-Growth
Topik	Analisis Pola dengan Association Rule Mining
Identitas Penyusun	1. Sheira En Nadia (23031554041) 2. Salsabila Rinita Candraningtyas (23031554179) 3. Fakhriatu J Koni (23031554186) 4. Alya' Hikmatul Rizkia (23031554229)
Kelas	2023 D

<b>1. PENDAHULUAN</b>  Pendahuluan penelitian tidak lebih dari 1000 kata yang terdiri dari: A. Latar belakang dan rumusan permasalahan yang akan diteliti B. Pendekatan pemecahan masalah
<b>1.1. Latar Belakang (min. 250 kata)</b>  Kemajuan teknologi yang sangat pesat di era ini secara tidak disadari telah mempengaruhi segala aspek kehidupan manusia, termasuk pada bidang politik, ekonomi, budaya, bahkan pendidikan. Perkembangan teknologi termasuk sesuatu yang tidak dapat dihindari pada kehidupan saat ini, sebab semakin maju ilmu pengetahuan maka semakin maju pula perkembangan teknologinya. Namun, hal tersebut sering berdampak pada perubahan sosial, kemiskinan, dan pengangguran yang pada akhirnya dapat memicu terjadinya konflik sosial, baik secara langsung maupun tidak langsung, dan hal tersebut dapat menimbulkan terjadinya kriminalitas [1].  Kriminalitas merupakan segala sesuatu yang dilakukan oleh individu, kelompok, ataupun komunitas yang melanggar hukum dengan mengambil sesuatu yang bukan menjadi haknya [2]. Kriminalitas merupakan tindakan yang dapat merugikan jiwa orang lain dan pelaku itu sendiri. Banyaknya kasus tindakan kriminal yang terjadi membuat masyarakat merasa tidak aman dan selalu merasa terancam di wilayah tertentu [3]. Selain itu, tindakan kriminalitas juga menunjukkan adanya pola tertentu.  Pola kriminalitas di Indonesia dipengaruhi oleh berbagai faktor sosial, ekonomi, dan lingkungan yang kompleks. Kondisi sosial seperti disorganisasi sosial, kemiskinan, serta urbanisasi menjadi pemicu utama meningkatnya kriminalitas di beberapa kota besar Indonesia. Disorganisasi sosial ini mencakup rendahnya status ekonomi,

tingginya mobilitas penduduk, serta keberagaman etnis yang memicu lemahnya kontrol sosial sehingga mendorong tindak kejahatan. Selain itu, pandemi COVID-19 merupakan kejadian luar biasa yang mempengaruhi pola kriminalitas, karena terjadi peningkatan kasus yang berkaitan dengan faktor ekonomi seperti pengangguran dan penurunan tekanan sosial [4].

Pola kriminalitas di perkotaan Indonesia menunjukkan bahwa kejahatan tersebar tidak merata dan cenderung berkelompok pada area-area tertentu. Misalnya seperti pencopetan dan pencurian yang sering sekali terjadi di tempat keramaian seperti pasar dan pusat perbelanjaan. Sementara pencurian kecil lebih banyak terjadi di permukiman kelas menengah ke bawah yang biasanya berada pada sistem keamanan yang lemah. Di kabupaten Sidoarjo menunjukkan korelasi yang kuat antara faktor ekologi kriminal seperti kepadatan penduduk, pemukiman padat, pengangguran, dan kawasan komersial dengan tingkat kriminalitas pencurian [5]. Pola spasial ini menggambarkan bahwa lingkungan fisik dan sosial sangat berperan dalam pembentukan pola kriminalitas di Indonesia.

Data statistik kriminal dari Badan Pusat Statistik (BPS) juga menunjukkan bahwa pencurian dan perampokan masih menjadi kejahatan yang paling dominan di Indonesia, diikuti oleh peningkatan kasus kekerasan dalam rumah tangga dan narkoba [6]. Para ahli kriminologi menegaskan bahwa kemiskinan dan ketidaksetaraan sosial merupakan faktor utama yang mendorong kriminalitas di Indonesia. Selain itu, perkembangan teknologi juga menyebabkan munculnya pola kejahatan baru seperti kejahatan siber yang semakin mengancam keamanan masyarakat di era digital.

Oleh karena itu, untuk menemukan sebuah pola kriminalitas yang semakin banyak dan menjadi rumit digunakanlah sebuah pendekatan teknologi data mining [7]. Proses data mining sendiri berguna untuk mengetahui informasi yang berasal dari data yang besar [8]. Salah satu teknik data mining yang banyak digunakan dalam analisis pola kriminalitas adalah association rule mining yang bertujuan untuk menemukan asosiasi antar berbagai variabel dalam data kejahatan/kriminalitas. Menggunakan pendekatan ini, dapat diidentifikasi kebiasaan atau kecenderungan tertentu dari pelaku kejahatan berdasarkan waktu, dan lokasi kejadian yang sering terjadi secara bersamaan, sehingga hasil analisis dapat dimanfaatkan sebagai informasi strategis bagi aparat penegak hukum dalam upaya pencegahan tindak kriminal [9], [10].

Algoritma Apriori dan FP-Growth merupakan dua metode populer dalam association rule mining. Apriori dikenal luas karena kemampuannya dalam menemukan aturan asosiasi berdasarkan frequent itemset, meskipun memiliki kelemahan dalam hal efisiensi pada dataset besar. Sementara itu, FP-Growth menawarkan solusi yang lebih efisien dengan membangun struktur pohon (FP-Tree) sehingga proses pencarian frequent pattern menjadi lebih cepat dan hemat sumber daya [9],[10]. Efektivitas algoritma FP-Growth memiliki kemampuan dalam menganalisis pola kriminalitas dengan efisiensi komputasi yang lebih baik dibanding Apriori [9]. Algoritma FP-Growth juga memiliki kemampuan untuk memproses data berskala besar, seperti data yang dimiliki oleh Kepolisian Daerah Yogyakarta [10].

Selain itu, analisis pola kriminalitas secara spatio-temporal, yaitu dengan mempertimbangkan dimensi ruang (lokasi) dan waktu, memberikan nilai tambah dalam memahami dinamika kejahatan. Dengan pendekatan ini, dapat diketahui kapan dan di mana kejahatan paling sering terjadi, serta bagaimana pola tersebut berubah dari waktu ke waktu. Integrasi aspek spatio-temporal dalam association rule mining telah dibuktikan mampu menghasilkan insight yang lebih komprehensif untuk mendukung pengambilan keputusan berbasis data [11].

## **1.2. Rumusan Masalah dan Tujuan**

### **Rumusan Masalah**

1. Bagaimana pola sebaran spasial (lokasi) dan temporal (waktu) tindak kriminalitas di wilayah dapat diidentifikasi menggunakan metode Association Rule Mining dengan algoritma Apriori dan FP-Growth?
2. Bagaimana penerapan dan efektivitas algoritma Apriori dan FP-Growth dalam menemukan pola asosiatif spatio-temporal dalam data kejahatan?
3. Algoritma mana yang lebih efektif dan efisien dalam mengungkap pola kriminalitas spatio-temporal, antara Apriori dan FP-Growth?
4. Bagaimana perubahan pola kriminalitas dari waktu ke waktu (temporal) dan persebaran geografisnya (spasial) di wilayah tertentu?

### **Tujuan**

1. Mengidentifikasi pola-pola kriminalitas yang tersebar secara spasial dan temporal menggunakan teknik Association Rule Mining dengan algoritma Apriori dan FP-Growth.
2. Menerapkan dan membandingkan kinerja algoritma Apriori dan FP-Growth dalam proses ekstraksi association rules dari data kriminalitas spatio-temporal.

3. Memetakan daerah-daerah rawan kriminalitas (hotspot) berdasarkan pola kejadian dan waktu terjadinya tindak kejahatan.
4. Menghasilkan pola-pola asosiatif yang dapat menjadi dasar dalam mendukung pengambilan keputusan untuk strategi pencegahan dan penanganan kejahatan berbasis lokasi dan waktu.

## 2. Metodologi

Metodologi atau cara untuk mencapai tujuan yang telah ditetapkan ditulis tidak melebihi 1000 kata. Bagian ini berisi metode pre-processing dan/atau metode post processing yang dilengkapi dengan diagram alir penelitian yang menggambarkan apa yang sudah dilaksanakan dan yang akan dikerjakan selama waktu yang diusulkan. Format diagram alir dapat berupa file JPG/PNG. Metode penelitian harus dibuat secara utuh dengan penahapan yang jelas.

### 2.1. Eksplorasi Dataset

Pemahaman dataset yang dimiliki

Eksplorasi awal dilakukan terhadap [Chicago Crime Dataset](#) yang diperoleh dari platform Kaggle. Dataset ini berisi catatan kejadian kriminal yang terjadi di Kota Chicago selama beberapa tahun, mencakup informasi:

1. Tanggal dan Waktu kejadian,
2. Tipe Kejahatan,
3. Lokasi Kejadian,
4. Status Penangkapan,
5. Serta koordinat geografis (latitude dan longitude).

Eksplorasi ini bertujuan untuk memahami struktur dataset, mengidentifikasi atribut-atribut penting yang relevan untuk analisis spatio-temporal, serta mengevaluasi kualitas data yang tersedia (termasuk mendeteksi missing values dan outlier).

### 2.2. Langkah Penelitian

1. Data Pre-processing
  - a. Data Cleaning: Menghapus duplikasi, memperbaiki nilai kosong, dan membuang atribut yang tidak relevan.
  - b. Transformasi Atribut: Ekstraksi elemen *tanggal* menjadi *bulan*, *hari dalam minggu*, dan *jam*, serta pengelompokan koordinat ke dalam zona tertentu untuk aspek spasial.
  - c. Encoding Data: Konversi atribut kategorikal menjadi format numerik agar dapat diproses oleh algoritma mining.

1. Association Rule Mining

- a. Apriori Algorithm: Menerapkan algoritma Apriori untuk mencari frequent itemsets berdasarkan threshold minimum support dan minimum confidence.
- b. FP-Growth Algorithm: Menerapkan algoritma FP-Growth untuk menghasilkan frequent itemsets lebih cepat dengan membangun FP-Tree, sehingga lebih efisien untuk dataset besar.

## 2. Evaluasi dan Perbandingan Algoritma

Membandingkan hasil yang diperoleh dari kedua algoritma berdasarkan:

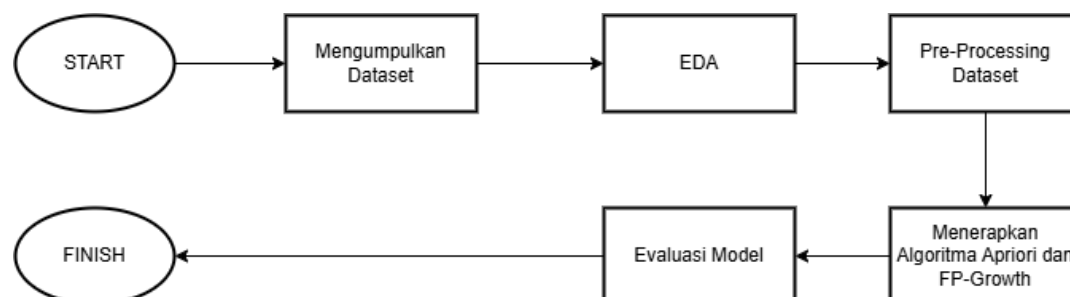
- a. Jumlah rule yang dihasilkan,
- b. Waktu komputasi,
- c. Nilai support, confidence, dan lift.

## 3. Analisis Pola Kriminalitas

Menginterpretasikan pola-pola asosiasi yang ditemukan, mengidentifikasi waktu-waktu rawan, lokasi berisiko tinggi, serta keterkaitan jenis kejahatan dengan faktor spasial dan temporal.

## 4. Penyusunan Kesimpulan dan Rekomendasi

Menyimpulkan hasil analisis dan memberikan rekomendasi strategis untuk pencegahan dan penanganan kejahatan di masa depan berbasis data.



Gambar 1.Flowchart

## 3. Hasil dan Analisis

### 3.1. Exploratory Data Analysis

#### 1. Pengecekan Duplikasi Data

```
df.duplicated().sum()
```

```
np.int64(0)
```

Hasilnya menunjukkan bahwa tidak terdapat baris data yang duplikat (0 duplikasi), sehingga data dapat langsung diproses ke tahap pembersihan dan analisis selanjutnya tanpa perlu menghapus baris duplikat.

## 2. Seleksi Kolom yang Relevan

	date	year	primary_type	community_area	location_description	arrest
0	2025-04-23 00:00:00	2025	BATTERY	44	SCHOOL - PUBLIC GROUNDS	False
1	2025-04-23 00:00:00	2025	CRIMINAL SEXUAL ASSAULT	8	HOTEL / MOTEL	False
2	2025-04-23 00:00:00	2025	STALKING	8	APARTMENT	False
3	2025-04-23 00:00:00	2025	DECEPTIVE PRACTICE	25	APARTMENT	False
4	2025-04-23 00:00:00	2025	MOTOR VEHICLE THEFT	46	STREET	False

Karena fokus utama analisis ini adalah untuk menemukan pola kriminal berdasarkan dimensi spasial (lokasi), temporal (waktu), dan jenis kejahatan, maka tidak semua kolom dalam dataset digunakan. Sehingga kami hanya menggunakan 5 fitur yaitu date, year, primary\_type, community\_area, location\_description, arrest.

## 3. Memecah Kolom Date menjadi bulan, hari, dan jam

	date	year	primary_type	community_area	location_description	arrest	hour	day	month
0	2025-04-23 00:00:00	2025	BATTERY	44	SCHOOL - PUBLIC GROUNDS	False	0	Wednesday	April
1	2025-04-23 00:00:00	2025	CRIMINAL SEXUAL ASSAULT	8	HOTEL / MOTEL	False	0	Wednesday	April
2	2025-04-23 00:00:00	2025	STALKING	8	APARTMENT	False	0	Wednesday	April
3	2025-04-23 00:00:00	2025	DECEPTIVE PRACTICE	25	APARTMENT	False	0	Wednesday	April
4	2025-04-23 00:00:00	2025	MOTOR VEHICLE THEFT	46	STREET	False	0	Wednesday	April
...	...	...	...	...	...	...	...	...	...
995	2025-04-21 12:20:00	2025	THEFT	25	RESIDENCE - YARD (FRONT / BACK)	False	12	Monday	April
996	2025-04-21 12:15:00	2025	BATTERY	68	APARTMENT	False	12	Monday	April
997	2025-04-21 12:05:00	2025	OTHER OFFENSE	75	PARKING LOT / GARAGE (NON RESIDENTIAL)	True	12	Monday	April
998	2025-04-21 12:02:00	2025	BATTERY	20	RESIDENCE	False	12	Monday	April
999	2025-04-21 12:02:00	2025	ASSAULT	21	CTA STATION	False	12	Monday	April

1000 rows x 9 columns

Penambahan fitur ini bertujuan untuk menangkap pola kejadian kriminal berdasarkan waktu spesifik.

## 4. Cek Data

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  ---                ---
0   date                  1000 non-null  datetime64[ns]
1   year                  1000 non-null  int64
2   primary_type          1000 non-null  object
3   community_area        1000 non-null  int64
4   location_description   999 non-null   object
5   arrest                1000 non-null  bool
6   hour                  1000 non-null  int32
7   day                   1000 non-null  object
8   month                 1000 non-null  object
dtypes: bool(1), datetime64[ns](1), int32(1), int64(2), object(4)
memory usage: 59.7+ KB
```

Terlihat bahwa hampir semua kolom pada dataset ini lengkap, kecuali location\_description yang hanya memiliki satu nilai kosong dari total 1000 baris. Mempunyai beberapa tipe data yaitu, bool (1), datetime64[ns](1), int32(1), int64(2), object(4).

## 5. Mengubah Info Fitur Numerik menjadi Kategorikal

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   date                   1000 non-null  datetime64[ns]
1   year                   1000 non-null  object  
2   primary_type           1000 non-null  object  
3   community_area          1000 non-null  object  
4   location_description    999 non-null   object  
5   arrest                  1000 non-null  bool    
6   hour                    1000 non-null  object  
7   day                     1000 non-null  object  
8   month                   1000 non-null  object  
dtypes: bool(1), datetime64[ns](1), object(7)
memory usage: 63.6+ KB

```

Proses ini dilakukan karena untuk analisis asosiasi seperti Apriori dan FP-Growth tidak memperhatikan nilai numerik atau urutan, melainkan hanya fokus pada kombinasi antar elemen yang unik.

## 6. Mengatasi Missing Value

```

Missing Values before handling:
date                0
year                0
primary_type        0
community_area      0
location_description 1
arrest              0
hour                0
day                 0
month               0
dtype: int64

```

Terdapat 1 missing value pada fitur location\_description, sedangkan pada fitur lainnya tidak ada missing value.

```


Missing Values after handling:
date                0
year                0
primary_type        0
community_area      0
location_description 0
arrest              0
hour                0
day                 0
month               0
dtype: int64

```

Setelah melakukan handling missing value dengan mengisi nilai kosong menggunakan modus pada fitur location\_description sehingga tidak ada missing value lagi.


## 7. Visualisasi Distribusi Data Tiap Fitur

### a. Fitur Date




Secara keseluruhan dapat terlihat bahwa adanya pola naik dan turun di tiap jam dan hari-nya. Pada tanggal 21 April siang hingga sore, terjadi kenaikan namun pada tanggal 21 April malam itu terjadi penurunan kasus yang terjadi. Hingga pada tanggal 22 April siang terjadi kenaikan kasus lagi hingga 23 April dini pagi.

b. Fitur Year




Dari histogram yang dihasilkan, seluruh data tercatat hanya dalam satu tahun, yaitu tahun 2025.

c. Fitur primary\_type



Distribusi yang terlihat dalam histogram memperlihatkan bahwa jenis kejahatan paling umum adalah THEFT, dilanjutkan oleh BATTERY dan CRIMINAL DAMAGE.


d. Fitur community\_area



Dari visualisasi tersebut terlihat bahwa kasus yang sering terjadi di community\_area nomor 25.


e. Fitur location\_description






Histogram menunjukkan bahwa lokasi yang paling sering dijadikan tempat kejadian adalah street, apartment, dan residence. Informasi ini berguna untuk mengidentifikasi lingkungan berisiko tinggi dan mengembangkan kebijakan keamanan berbasis lokasi.

f. Fitur arrest




Fitur arrest ini berisi terjadi sebuah penangkapan ke pelaku oleh pihak berwajib atau tidak di tiap kasus kriminal. Nilai 0 sebagai tidak ada penangkapan, sedangkan nilai 1 sebagai ada penangkapan. Terlihat bahwa lebih banyak tidak terjadi penangkapan daripada terjadi sebuah penangkapan.

g. Fitur hour




Histogram memperlihatkan bahwa kejadian kriminal tersebar cukup merata dari siang hingga malam hari, dengan frekuensi terbanyak pada jam 15 dan 18.

h. Fitur day



Dari distribusi data tersebut terlihat kasus yang sering terjadi pada hari Selasa.

#### i. Fitur Month



Pada dataset ini semua kejadian terjadi hanya di bulan April.

## 3.2. Insight dan Hasil Mining dari Project

### 1. One Hot Encoding

	0	1	10	11	12	13	14	15	16	17	...	STALKING	STREET	THEFT	True	Tuesday	VACANT LOT	VACANT LOT / LAND	VEHICLE NON-COMMERCIAL	WEAPONS VIOLATION	Wednesday
0	True	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	True
1	True	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	True
2	True	False	False	False	False	False	False	False	False	False	...	True	False	False	False	False	False	False	False	False	True
3	True	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	True
4	True	False	False	False	False	False	False	False	False	False	...	False	True	False	False	False	False	False	False	False	True
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
995	False	False	False	False	True	False	False	False	False	False	...	False	False	True	False	False	False	False	False	False	False
996	False	False	False	False	True	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
997	False	False	False	False	True	False	False	False	False	False	...	False	False	False	True	False	False	False	False	False	False
998	False	False	False	False	True	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
999	False	False	False	False	True	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False

1000 rows x 701 columns

Mengubah data kategorik menjadi format transaksi menggunakan one hot encoding. Karena ARM tidak dapat memproses data tabular biasa.

### 2. Algoritma Apriori

Aturan dari Apriori:

	antecedents	consequents	support	confidence	lift
457	(NARCOTICS)	(True, 2025)	0.034	0.894737	5.698961
456	(NARCOTICS, 2025)	(True)	0.034	0.894737	5.698961
1098	(NARCOTICS)	(True, 2025, April)	0.034	0.894737	5.698961
1096	(NARCOTICS, 2025)	(True, April)	0.034	0.894737	5.698961
1094	(NARCOTICS, 2025, April)	(True)	0.034	0.894737	5.698961
120	(NARCOTICS)	(True)	0.034	0.894737	5.698961
1097	(NARCOTICS, April)	(True, 2025)	0.034	0.894737	5.698961
583	(NARCOTICS)	(True, April)	0.034	0.894737	5.698961
582	(NARCOTICS, April)	(True)	0.034	0.894737	5.698961
588	(SMALL RETAIL STORE, April)	(THEFT)	0.030	0.769231	3.126954

Algoritma Apriori dalam analisis ini menggunakan nilai min\_support = 0.03, yang berarti hanya itemset yang muncul minimal 3% dari total transaksi

(setara dengan  $\geq 30$  kali jika total transaksi 1000) yang akan dipertimbangkan. Pemilihan nilai ini bertujuan untuk menjaga keseimbangan antara spesifisitas dan generalisasi pola: jika nilai `min_support` terlalu kecil (misalnya 0.01 atau 0.02), hasilnya menjadi terlalu umum karena memasukkan itemset yang hanya muncul sesekali, sehingga kurang bermakna. Sedangkan jika terlalu besar, berisiko mengabaikan pola-pola penting yang tidak terlalu sering muncul, yang bisa menyebabkan underfitting. Oleh karena itu, nilai 0.03 dipilih sebagai titik tengah agar hasil yang diperoleh tetap relevan dan tidak terlalu banyak maupun terlalu sedikit.

Dari hasil penerapan algoritma Apriori tersebut menghasilkan rules sebagai berikut:

**Dari hasil rules 3 teratas, pola yang tercipta adalah:**

1. Jika terjadi kasus kriminalitas berupa penggunaan narkoba, maka itu terjadi pada bulan April dan terjadi penangkapan pada pelaku
2. Jika terjadi kasus kriminalitas berupa kecanduan narkoba pada bulan april, maka pelaku tersebut ditangkap
3. Jika terjadi kasus kriminalitas ketergantungan narkoba, maka itu terjadi pada tahun 2025 dan pelakunya ditangkap

### 3. Algoritma FP-Growth

Aturan dari FP-Growth:

	antecedents	consequents	support	confidence	lift
1113	(NARCOTICS, April)	(True, 2025)	0.034	0.894737	5.698961
1114	(NARCOTICS)	(True, 2025, April)	0.034	0.894737	5.698961
1098	(NARCOTICS)	(True)	0.034	0.894737	5.698961
1106	(NARCOTICS, 2025)	(True)	0.034	0.894737	5.698961
1103	(NARCOTICS, April)	(True)	0.034	0.894737	5.698961
1107	(NARCOTICS)	(True, 2025)	0.034	0.894737	5.698961
1110	(NARCOTICS, 2025, April)	(True)	0.034	0.894737	5.698961
1112	(NARCOTICS, 2025)	(True, April)	0.034	0.894737	5.698961
1104	(NARCOTICS)	(True, April)	0.034	0.894737	5.698961
1204	(SMALL RETAIL STORE)	(THEFT, 2025)	0.030	0.769231	3.126954

Algoritma FP-Growth pada analisis ini juga menggunakan `min_support` = 0.03, artinya hanya itemset yang muncul minimal 3% dari total transaksi yang akan dipertimbangkan sebagai frequent itemsets. Nilai ambang ini dipilih agar hasil

yang diperoleh tetap relevan tanpa terlalu banyak itemset yang jarang muncul, sekaligus menghindari hilangnya pola penting jika ambang terlalu tinggi.

Dari penerapan algoritma FP-Growth tersebut menghasilkan aturan sebagai berikut:

**Dari hasil rules 3 teratas, pola yang tercipta adalah:**

1. Jika terjadi kasus kriminalitas berupa penggunaan narkoba, maka kasus itu hampir pasti terjadi pada bulan April di tahun 2025 dan terjadi penangkapan pada pelaku
2. Jika terjadi kasus kriminalitas berupa kecanduan narkoba, besar kemungkinan pelaku tersebut ditangkap
3. Jika terjadi kasus kriminalitas ketergantungan narkoba pada bulan April, maka terdapat kemungkinan pelaku tersebut tertangkap oleh pihak berwajib

#### **4. Jumlah Aturan setiap algoritma**

Jumlah aturan dari Apriori: 1506

Jumlah aturan dari FP-Growth: 1506

Jumlah aturan pada kedua algoritma tersebut sama, menandakan bahwa kedua model dapat memproses semua data yang ada.

**Dari kedua hasil algoritma tersebut dapat diambil beberapa rules yang penting:**

1. Jika terjadi kasus kriminalitas berupa penggunaan narkoba pada bulan april 2025, maka kasus tersebut hampir pasti terjadi penangkapan
2. Jika lokasi kejadiannya di small retail store, maka kemungkinan besar jenis kriminalitasnya adalah pencurian
3. Jika terdapat kasus pencurian motor, maka kemungkinan besar terjadi pada bulan April 2025 dan berada di jalanan.

#### **4. Daftar Pustaka**

Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan, mengikuti format APA. Hanya pustaka yang disitasi pada usulan penelitian yang dicantumkan dalam Daftar Pustaka. Pustaka yang disitasi maksimal 8 tahun terakhir sebanyak minimal 10 pustaka.

- [1] Handayani, R. (2017). Analisis Dampak Kependudukan terhadap Tingkat Kriminalitas di Provinsi Banten. *Jurnal Administrasi Publik Volume 8, Nomor 2, Desember 2017*, 8(2), 103-217.

- [2] Rahmadayanti, F., & Rahayu, R. (2023). Penerapan Metode Data Mining Pada Kasus Kriminalitas Indonesia. *Jurnal Teknologi Informasi Mura*, 15(1), 52-61.
- [3] Dila Aulia Putri, Yani Maulita, & Hermansyah Sembiring. (2024). Penerapan Algoritma Apriori Mengetahui Pola Tindakan Kriminal Berdasarkan Wilayah (Studi Kasus : Polsek Sunggal). *Bridge : Jurnal Publikasi Sistem Informasi Dan Telekomunikasi*, 2(4), 32-46.
- [4] Abdissiam, D. A., & Pratomo, R. A. (2024). Dinamika jumlah dan pola sebaran kriminalitas sebelum hingga setelah COVID-19 di Kelurahan Damai, Kota Balikpapan. *Region: Jurnal Pembangunan Wilayah dan Perencanaan Partisipatif*, 19(2), 465-480.
- [5] Ashari, R., & Susetyo, C. (2020). Identifikasi Pola Spasial Kriminalitas Kota Berdasarkan Faktor Ekologi Kriminal di Kabupaten Sidoarjo. *Jurnal Teknik ITS*, 9(1), C1-C6.
- [6] Badan Pusat Statistik Indonesia. (15 Desember 2021). *Statistik Kriminal 2021*. Diakses pada 28 April 2025, dari <https://www.bps.go.id/id/publication/2021/12/15/8d1bc84d2055e99feed39986/statistik-kriminal-2021.html>
- [7] Sevri, M., Karacan, H., & Akcayol, M. A. (2017). Crime analysis based on association rules using apriori algorithm. *International Journal of Information and Electronics Engineering*, 7(3), 99-102.
- [8] Juledi, A. P. ., Defit, S. ., & Yuhandri, Y. (2021). Analisis Tingkat Kejahatan pada Anak Dibawah Umur Menggunakan Metode FP-Growth. *Jurnal Sistim Informasi Dan Teknologi*, 2(1), 29-34.
- [9] Winarti, D., Revita, E., & Yandani, E. (2021). Penerapan Data Mining untuk Analisa Tingkat Kriminalitas Dengan Algoritma Association Rule Metode FP-Growth. *Simtika*, 4(3), 8-22.
- [10] WASITO, S. (2017). *Analisis Pola Kriminalitas Menggunakan Algoritma FP-Growth (Studi Kasus: Kepolisian Resor Kota Yogyakarta)* (Doctoral dissertation, Universitas Gadjah Mada).
- [11] Mauliani, A., Hartati, S., & Musdholifah, A. (2016). Pembentukan Temporal Association Rules Menggunakan Algoritma Apriori (Studi Kasus: Toko Batik Diyan Solo). *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, 10(1), 71-80.